

Harshil Gorasiya

LLM-Systeme: Retrieval, Agenten und Forschung zu kleinen Modellen

LLM-Anwendungen · RAG · KI-Agenten · LLM-Forschung

Heilbronn, Deutschland | +49 155 6351 7346 | harshil.gorasiya.0011@gmail.com
LinkedIn: linkedin.com/in/harshil-gorasiya-054a58319
GitHub: github.com/N0t-Harshil | Portfolio: harshil-0011.github.io/My-Portfolio

Gesucht: Werkstudentenstelle (20 Std./Woche im Semester) · Vollzeit in den Semesterferien · Berufseinstieg im Bereich LLM/RAG ab 2027
Verfügbar: ab sofort | **Aufenthaltstitel:** gültige Aufenthaltserlaubnis mit Arbeitserlaubnis

0,654	8,1 ms	28–32 FPS	79 %	250 Tests
nDCG@10, BEIR SciFact, 300 Anfragen	Overhead je Agent-Schritt (Laptop-CPU)	YOLOv8n auf reiner CPU	Genauigkeit, zuvor 71 %	pytest-Suite, Ekdant

KURZPROFIL

Masterstudent an der Hochschule Heilbronn mit Schwerpunkt auf LLM-Anwendungen. Ich entwickle lokale RAG-Systeme mit hybrider Suche, KI-Agenten mit Tool-Nutzung und forsche in einem betreuten Projekt an einem Reasoning-Modul für Sprachmodelle. Dazu kommen zwei ML-Praktika und eine Anstellung in der KI-gestützten Webentwicklung.

STUDIUM

seit 03/2025 — **M.Sc. Software Engineering and Management** | Hochschule Heilbronn
Englischsprachiges Studienprogramm | Notendurchschnitt bisher: 1,9 | voraussichtlicher Abschluss: 2027

2020 – 2024 — **B.Tech. Information Technology** | A. D. Patel Institute of Technology, Gujarat
Indien | Note: 1,9 (umgerechnet auf deutsche Skala)

PROJEKTE

KI-Agent — **Ardan-CLI: autonomer Coding-Agent für das Terminal**
TypeScript (strict), Node.js 24, 0 Laufzeit-Abhängigkeiten, MCP, LSP

- Agent-Schleife mit Streaming, **35 Tools**, Plan-Modus, Sub-Agenten und Checkpoints; **8 LLM-Anbieter** mit automatischem Failover.
- SSE/NDJSON-Streaming, MCP- und LSP-Client ohne SDKs; Fallback-Parser für Modelle ohne Function Calling.
- **8,1 ms** Overhead pro Agent-Schritt (Benchmark auf Laptop-CPU); CI auf Linux, macOS, Windows.

Recherche-Engine — **Local Perplex: lokaler KI-Recherche-Assistent mit Quellenbelegen**
Python, FastAPI, SSE, SQLite, Ollama, Docker

- Durchsucht Web und eigene Dokumente (PDF, Word, Excel u. a.), liest Seiten parallel und streamt Antworten mit Zitaten; **26 LLM-Anbieter**, 7 Suchbackends, auf Wunsch vollständig lokal.
- Eigener BM25-Ranker: **nDCG@10 von 0,654** auf BEIR SciFact, 300 Anfragen (Vorversion 0,038; Anserini-Referenz 0,665), 9,5 ms pro Anfrage.
- Antwortseite in ca. **200 ms**; Wissensgraph in SQLite (Schreiben 77× schneller); **55 Tests**, 76 % Abdeckung, CI unter Ubuntu und Windows.

RAG-System — **ANVITHA: lokale Wissensdatenbank mit belegten Antworten**
Python, FastAPI, Ollama, SQLite, NumPy, BM25

- Macht aus PDF-, TXT- und Markdown-Dateien eine vernetzte Markdown-Wissensdatenbank; Antworten stammen nur daraus und verweisen auf die Seite der Originaldatei.
- Fakten werden vor dem Speichern gegen den Quelltext geprüft; jeder Satz der Antwort wird danach gegen die Datenbank geprüft, nicht belegte Teile werden entfernt.
- Fragen außerhalb der Datenbank werden in unter 0,3 s ohne Modellaufruf abgelehnt.
- Getestet mit einem lokalen 0,8-Mrd.-Parameter-Modell (Ollama): 8 von 8 abgedeckten Fragen beantwortet (12 Testfragen insgesamt), Median 7,4 s bis zur vollständigen Antwort; 26 automatisierte Tests in ca. 1,5 s.

Masterarbeit (laufend)

Ekdant: Reasoning-Modul (Debate-Sandbox) für Sprachmodelle
Hochschule Heilbronn, betreut durch einen Professor | Python, PyTorch, Hugging Face

- Forschungsfrage: Verbessert ein paralleles Debatten-Modul (4 Trajektorien, 2 Runden, Konsens) das Schlussfolgern eines LLM? Umsetzung in PyTorch als zero-initialisiertes Residual-Modul (**+19,59 Mio. Parameter**) auf SmolLM2-135M.
- A/B-Vergleich mit architekturgleicher Baseline auf medizinischer QA (PubMedQA, MedQuAD), leckagefreier Split nach Frage; Metriken: Perplexität, ROUGE-L, Token-F1, gepaartes Bootstrap-Konfidenzintervall.
- Beste Variante (Modul als letzte Stufe) schlägt die Baseline in allen Metriken, aber nur knapp (Perplexität **3,783 auf 3,776**, ein Lauf); Pilot von Grund auf ohne Unterschied; zweiter Seed geplant.
- **250 pytest-Tests**; 4 Designfehler gefunden und behoben; Literaturbasis mit 66 Papern.

Weitere Projekte

KI-Videohochskalierung | Python, PyTorch
Windows-Desktop-Anwendung für Video-Super-Resolution mit Modellauswahl und Laufzeit-Monitoring; Real-ESRGAN-Varianten mit PSNR und SSIM verglichen.

MNIST-MLOps | Python, PyTorch, Flask, SQLite
Demo eines MLOps-Workflows: inkrementelles Training, Metriken und Modellversionen in SQLite, Web-Dashboard.

BERUFSERFAHRUNG

05/2024 – 02/2025 (10 Monate)

AI & Web Solutions Developer | Aani Brothers Infotech, Surat, Indien

- Entwicklung webbasierter Anwendungen: Geschäftsanforderungen in Benutzeroberflächen und Anwendungsabläufe übersetzt.
- Mitarbeit an Webprojekten mit KI-Funktionen; Anforderungen in die Nutzererfahrung integriert.
- Nutzerforschung, Wireframing, Prototyping; Designs iterativ für Usability und Konsistenz optimiert.

12/2023 – 04/2024 (5 Monate)

Deep Learning Intern | PD Avenue, Surat, Indien

- CNN mit Residual-Blöcken (TensorFlow/Keras) zur Alters- und Geschlechtsklassifikation auf **22.000+ Bildern**; Validierungsgenauigkeit von **71 % auf 79 %** gesteigert (Architektur-Optimierung, klassenbalancierte Augmentierung).
- Trainingszeit auf V100-GPUs um **20 %** gesenkt (Cosine-Learning-Rate-Scheduling, größere Batchgröße), ohne Genauigkeitsverlust.
- Data-Leakage-Problem behoben; Zuverlässigkeit über **10+ Trainingsläufe** gesichert.

05/2023 – 06/2023 (2 Monate)

Machine Learning Intern | Dotcom IoT LLP, Surat, Indien

- YOLOv8n-Objekterkennung auf CPU-Edge-Gerät (Intel Core i7): 720p-Video mit **28–32 FPS**; **2,4× höherer Durchsatz** als die YOLOv5s-Baseline.
- **3.000+ Bilder** in fünf Fahrzeugklassen kuratiert und annotiert.
- IoU- und NMS-Parameter optimiert: Falsch-Positive bei wenig Licht um **18 %** reduziert (eigener Nacht-Testdatensatz).
- Inferenz und Visualisierung als einsatzbereite Python-Anwendung mit Benchmarking gebündelt.

KENNTNISSE

LLM & RAG	RAG, hybride Suche (BM25, Embeddings), fundierte Antworten, Ollama, ReAct-Agenten, Anthropic API, MCP, Prompt Engineering
LLM-Forschung	Fine-Tuning, Transformer-Architekturen (GQA, SwiGLU), A/B-Experimentdesign, PyTorch, Hugging Face Transformers
ML & Vision	PyTorch, TensorFlow/Keras, scikit-learn, YOLOv8, CNNs, OpenCV
Engineering	Python, TypeScript, SQL, Bash, Git, Docker, Linux, pytest, CI (GitHub Actions), REST-APIs, FastAPI, Flask, MLflow, SQLite, PostgreSQL, MongoDB, AWS (Grundkenntnisse)
Evaluation	Latenz- und Durchsatz-Benchmarking, nDCG@10 (BEIR), Validierungsgenauigkeit, Falsch-Positiv-Analyse, PSNR/SSIM, Perplexität, ROUGE-L, Token-F1, gepaarter Bootstrap

ZERTIFIKATE

2026	Claude with the Anthropic API | Model Context Protocol: Advanced Topics (beide Anthropic)
2025	Machine Learning with Python (IBM) | Fundamentals of Data Science (Databricks)
Weitere	CRISP-DM on the AWS Stack | Big Data with Spark and Hadoop | AWS Academy Cloud

SPRACHEN

Englisch: fließend | **Deutsch:** A2–B1 (Selbsteinschätzung) | **Hindi:** fließend | **Gujarati:** Muttersprache

Heilbronn, 05.11.2026