# HARSHIL GORASIYA



## CONTACT INFO


HEILBRONN, DE

0155 6351 7346

HARSHIL.GORASIYA.0011@GMAIL.COM

LINKEDIN.COM/IN/HARSHIL-GORASIYA-054A58319/


## FÄHIGKEITEN

- Python
- Maschinelles Lernen
- Deep Learning
- Datenanalyse
- MLOps
- LLM-Anwendungen
- RAG-Systeme
- Computer Vision
- Modellbereitstellung
- Experimentieren und Optimierung

## BILDUNG

*M.Sc. Software Engineering and Management*
2025 – heute

*B.Tech. Information Technology*
2020 – 2024

## PROFIL

M.Sc.-Student im Studiengang Software Engineering und Management an der Hochschule Heilbronn mit praktischer Erfahrung in den Bereichen KI-Systeme, autonome Agenten und multimodale Suchtechnologien. Im Rahmen einer 17-monatigen eigenständigen Forschungs- und Entwicklungsarbeit entwickelte ich einen autonomen Programmieragenten, ein graphbasiertes RAG-System und eine lokale multimodale Suchmaschine. Ich bin von Anthropic für die Claude-API und das Model Context Protocol zertifiziert und verfüge über fundierte Kenntnisse in Python, C++ und MLOps.

## PRAKTISCHE ERFAHRUNG

### Praktikant im Bereich Deep Learning
PD Avenue
12.*2023 – 04.2024*

- *Entwicklung eines TensorFlow/Keras-CNN mit Residual-Block-Architektur zur Klassifizierung von Alter und Geschlecht anhand eines Datensatzes mit 22.000 Bildern, wobei die Validierungsgenauigkeit durch Architekturoptimierung und klassenausgleichende Augmentierung von 71 % auf 79 % verbessert wurde*
- *Reduzierung der Trainingszeit auf V100-GPUs um 20 % durch kosinusförmige Lernratenplanung und größere Batch-Größen bei gleichbleibender Genauigkeit*
- *Ein kritisches Problem mit Datenlecks wurde identifiziert und behoben, wodurch die Zuverlässigkeit der Experimente über mehr als 10 strukturierte Trainingsläufe hinweg verbessert wurde*

### Praktikant im Bereich maschinelles Lernen
Dotcom IoT LLP
05.*2023 – 06.2023*

- Implementierung einer YOLOv8n-Objekterkennungspipeline auf einem Edge-Gerät mit reiner CPU-Ausrüstung (Intel Core i7), das bei 720p-Videos mehr als 35.000 Frames pro Stunde mit 28–32 FPS verarbeitet – wodurch ein 2,4-mal höherer Durchsatz als bei einer YOLOv5s-Baseline erreicht wurde
- Es wurden mehr als 3.000 Bilder aus fünf Fahrzeugklassen kuratiert und annotiert; durch IoU- und NMS-Optimierung konnten Fehlalarme bei schlechten Lichtverhältnissen um 18 % reduziert werden, was anhand eines speziellen Nacht-Testdatensatzes validiert wurde

### Frontend-Entwickler
Aani Brother Infotech
05.*2024 – 02.2025*

- Entwicklung nutzerzentrierter Web- und Mobil-Oberflächen, bei der geschäftliche Anforderungen in intuitive, detailgetreue Nutzererlebnisse umgesetzt wurden, die die Benutzerfreundlichkeit und die Nutzerbindung verbesserten
- Durchführung von Nutzerforschung, Wireframing, Prototyping und iterativer Designoptimierung, um die Nutzererlebnisse zu verbessern und konsistente, skalierbare Designsysteme sicherzustellen

## EIGENSTÄNDIGE F&E — Juni 2024 bis September 2025

### Ardan-CLI – Autonomer Multi-Provider Coding-Agent

Funktionsfähige Demo : github.com/NOt-Harshil/Ardan-CLI

- Vollständiger ReAct-Loop (Planen → Ausführen → Beobachten → Auto-Korrektur → Review) in ~4.000 Zeilen Python; latenzbasiertes Failover über 6 LLM-Provider (Claude, GPT-4.1, Gemini, Groq, Mistral, Ollama)
- Parallele Tool-Ausführung (Git, Docker, C++-Compiler, Test-Runner); AES-256-verschlüsselte Schlüsselspeicherung, multimodale Bildeingabe und Session-Undo/Diff

### Anvitha RAG – Wissensgraph-Retrieval-System

Funktionsfähige Demo : github.com/NOt-Harshil/Anvitha-RAG

- 5-Ebenen-Dokumentenwissensgraph (Dokument → Satz) mit FAISS + Ollama; 75 Seiten / 225 KB in 19 Sekunden indexiert bei 100 % lokaler Inferenz
- Mittlere Abfragelatenz 4 Sekunden ohne signifikante Verschlechterung von 9 KB bis 226 KB (10 Abfragen × 5 Korpusgrößen); Ersatz eines Microsoft-GraphRAG-Prototyps

### Local Perplex – Offline Multimodale Recherche-Engine

Funktionsfähige Demo : github.com/NOt-Harshil/Local-Perplex

- Nativer C++ Multithread-Ranker (Producer-Consumer-Queue, POSIX-Threads): unter 10 ms Ranking-Latenz über 10.000+ Dokumente; Retrieval-Pipeline: 3–8 Sekunden
- Vollständig offline: lokale OCR (Tesseract), Vision-Inferenz (quantisiertes LLaVA), Multi-Format-RAG-Speicher (PDF, Word, Excel, CSV, Markdown)

### AI-Video-Upscaling – Windows-Desktop-App

Funktionsfähige Demo : github.com/NOt-Harshil/AI-Video-Upscaling

- Real-ESRGAN-Super-Resolution mit dynamischer Modellauswahl und GPU-Monitoring; vergleichende Evaluierung anhand PSNR und SSIM auf standardisiertem 30-Clip-Benchmark

## KENNTNISSE & FÄHIGKEITEN

●●●●● EXPERTE ●●●●○ FORTGESCHRITTEN ●●●○○ SOLIDE PRAXIS ●●○○○ GRUNDKENNTNISSE

| | |
|---|---|
| **Programmierung** ●●●●● | **Python (Haupts.), C++ (Systeme), SQL, Bash** |
| **ML / Computer Vision** ●●●●○ | **PyTorch, TensorFlow/Keras, Hugging Face Transformers, scikit-learn, YOLOv8, Real ESRGAN** |
| **LLM / RAG / Agentic** ●●●●● | **LangChain, FAISS, SentenceTransformers, Ollama, Anthropic API, MCP, Quantisierung (GGUF/AWQ), ReAct** |
| **MLOps / Engineering** ●●●●○ | **MLflow, Docker, FastAPI, REST APIs, Git, Linux, Multithreaded C++** |
| **Cloud / Datenbanken** ●●●○○ | **AWS (S3, EC2), PostgreSQL, MongoDB, SQLite** |

## SPRACHKENNTNISSE

- Englisch C1 – Verhandlungssicher
- Deutsch A2–B1 (aktiv ausgebaut)

## ZERTIFIKATE & WEITERBILDUNG

- Anthropic: Claude mit der Anthropic-API → verifizierbar via Skilljar
- Anthropic: Model Context Protocol – Fortgeschrittene Themen → verifizierbar via Skilljar
- Databricks: Grundlagen der Datenwissenschaft
- IBM: Maschinelles Lernen mit Python

